Estatísticas & Aquicultura.

Com: Carlos Antônio Zarzar

carlos.zarzar@ufopa.edu.br

Estatísticas & Aquicultura.

Com: Carlos Antônio Zarzar

carlos.zarzar@ufopa.edu.br

Apresenta: Métodos computacionais

- Método de Monte Carlo;
- Método de Monte Carlo via Cadeia de Markov;
- Algoritmo de amostragem;
  - Gibbs;
  - Metropolis-Hasting;

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

Geração de variáveis aleatórias independentes com mesma distribuição

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

$$\int_0^h f(x)dx = \int_{-2}^{2} -x^2 + 4\;dx$$

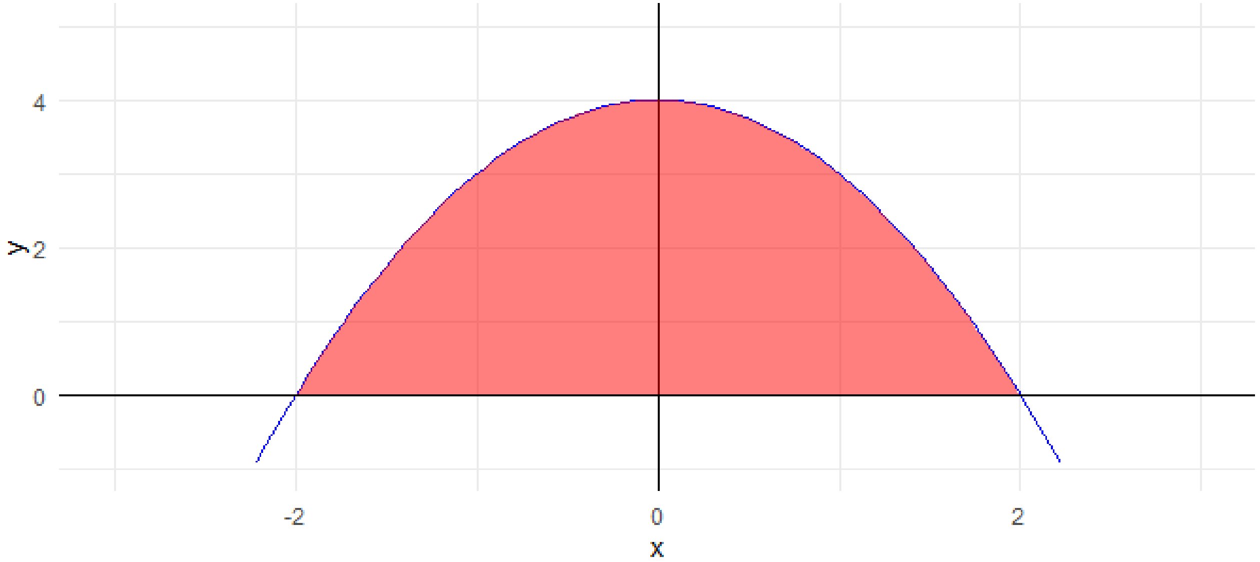

Geração de variáveis aleatórias independentes com mesma distribuição

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

$$\int_0^h f(x)dx = \int_{-2}^{2} -x^2 + 4\, dx$$

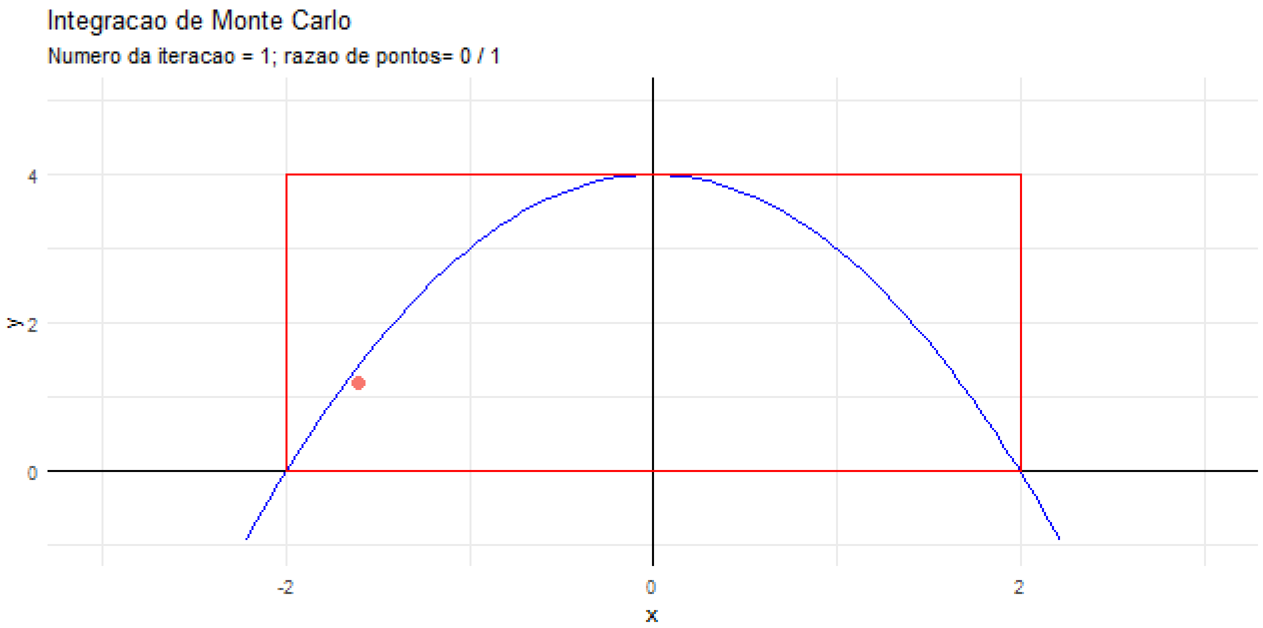

Geração de variáveis aleatórias independentes com mesma distribuição

- Número de pontos **fora** da curva = 172;
- Número de pontos **abaixo** da curva = 328;
- Número de pontos **Totais** = 500;

Área $f(x)$ = $\dfrac{\text{Número} \bullet}{\text{Número} \bullet}$ 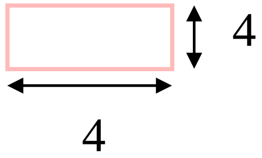

$$\int_0^h f(x)dx = \int_{-2}^{2} -x^2 + 4\ dx$$

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

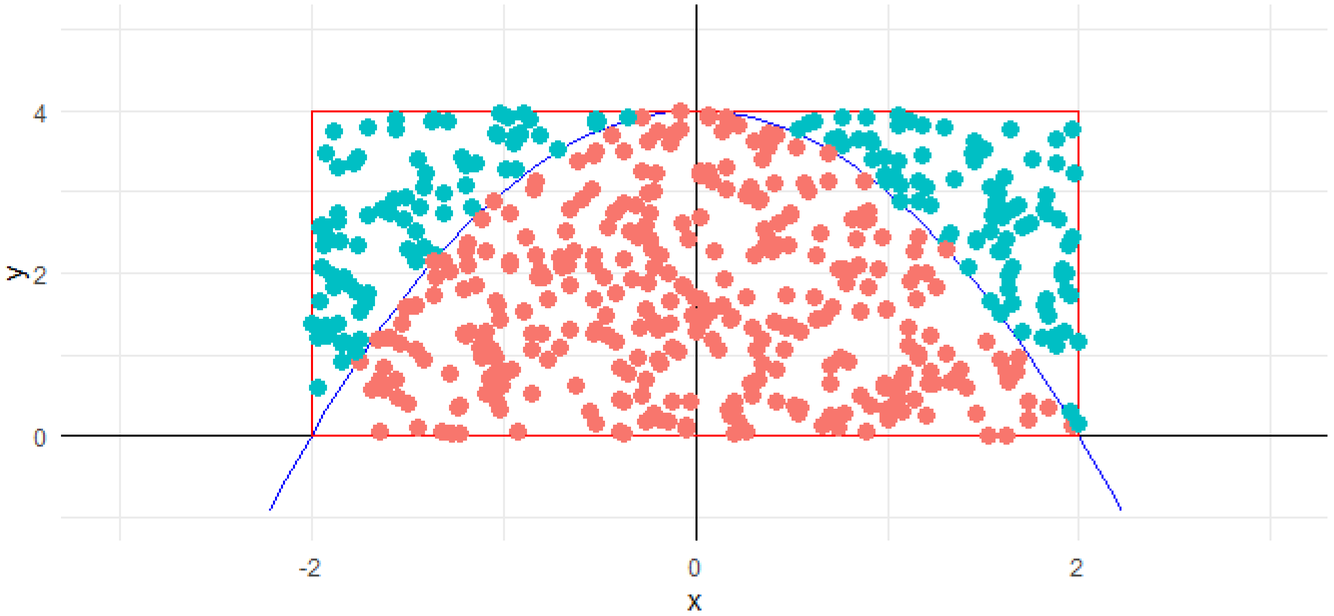

Geração de variáveis aleatórias independentes com mesma distribuição

- Número de pontos **fora** da curva = 172;
- Número de pontos **abaixo** da curva = 328;
- Número de pontos **Totais** = 500;

$$\text{Área } f(x) = \frac{\text{Número}}{\text{Número}} \times 4 \times 4$$

➢ Lei Forte dos Grandes Números

Seja $Y_1, Y_2, \ldots, Y_n$ variáveis $i.i.d.$

$$\mu = E[Y] < \infty$$

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \to \mu$$ Convergindo quase certo $n \to \infty$

$$P\left(\lim_{n\to\infty} \frac{1}{n}\sum_{i=1}^{n} Y_i = \mu\right) = 1$$

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

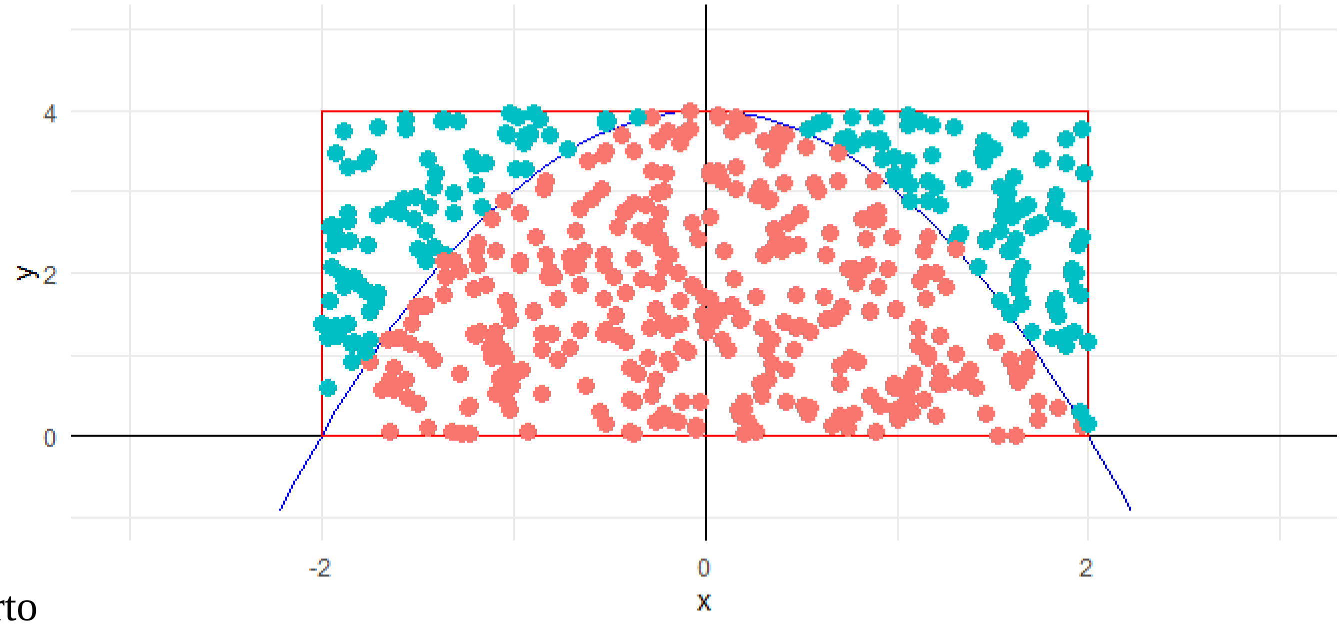

Geração de variáveis aleatórias independentes com mesma distribuição

- Número de pontos **fora** da curva = 172;
- Número de pontos **abaixo** da curva = 328;
- Número de pontos **Totais** = 500;

Área $f(x)$ = $\dfrac{\text{Número}}{\text{Número}}$

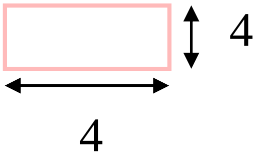

➢ Lei Forte dos Grandes Números

$$\text{Seja } Y_1, Y_2, \ldots, Y_n \text{ variáveis } i.i.d.$$

$$\mu = E[Y] < \infty$$

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \rightarrow \mu$$ Convergindo quase certo $n \rightarrow \infty$

$$P\left(\lim_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n} Y_i = \mu\right) = 1$$

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

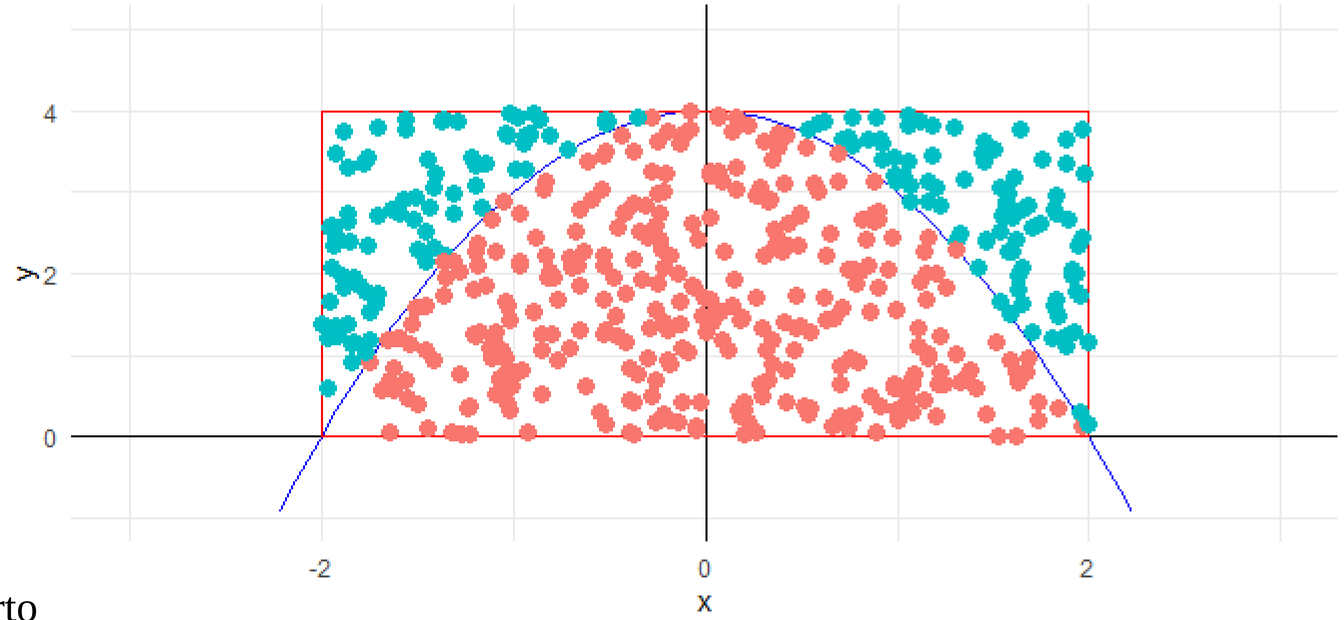

$$\text{Área } f(x) = \frac{172}{500} * (4x4) = 10{,}496$$

$$\int_0^h f(x)dx = \int_{-2}^{2} -x^2 + 4\, dx = 10{,}667$$

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

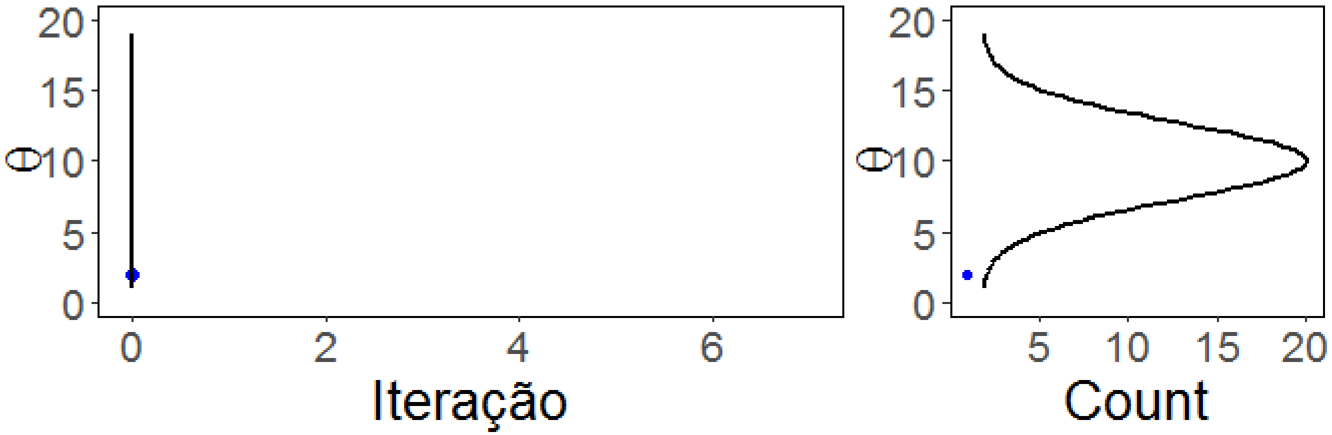

Geração de variáveis aleatórias independentes com mesma distribuição

- Lei Forte dos Grandes Números

Seja $Y_1, Y_2, \ldots, Y_n$ variáveis *i.i.d.*

$$\mu = E[Y] < \infty$$

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \to \mu$$ Convergindo quase certo $n \to \infty$

$$P\left(\lim_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n} Y_i = \mu\right) = 1$$

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

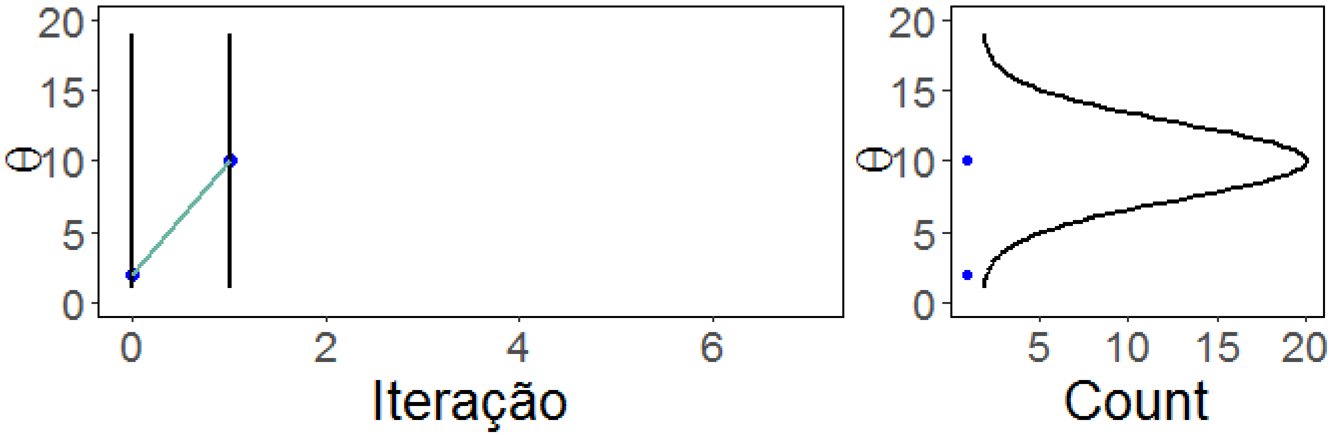

Geração de variáveis aleatórias independentes com mesma distribuição

➢ Lei Forte dos Grandes Números

Seja $Y_1, Y_2, \ldots, Y_n$ variáveis *i.i.d.*

$$\mu = E[Y] < \infty$$

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \to \mu$$

Convergindo quase certo $n \to \infty$

$$P\left(\lim_{n\to\infty} \frac{1}{n}\sum_{i=1}^{n} Y_i = \mu\right) = 1$$

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

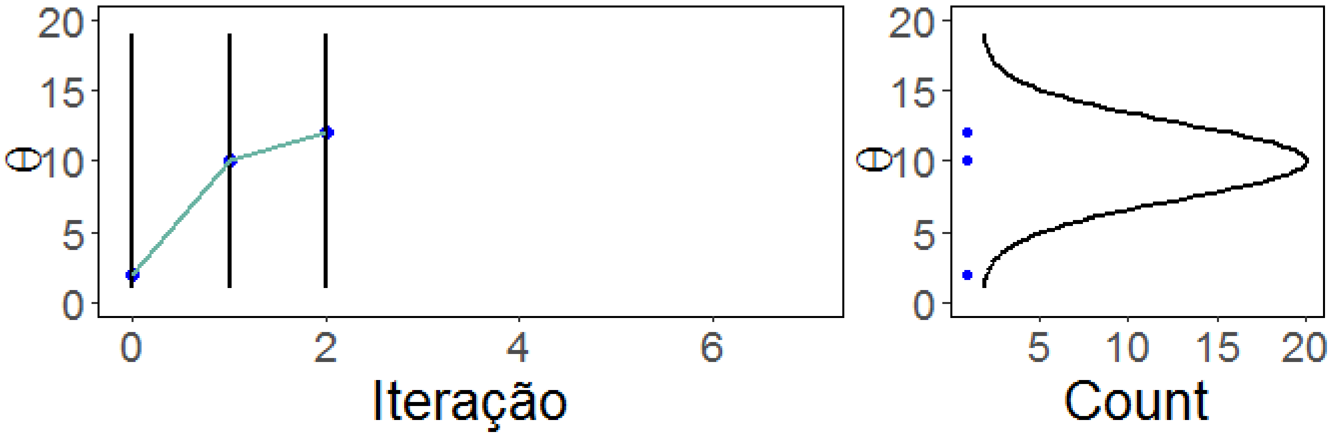

Geração de variáveis aleatórias independentes com mesma distribuição

- Lei Forte dos Grandes Números

Seja $Y_1, Y_2, \ldots, Y_n$ variáveis *i.i.d.*

$$\mu = E[Y] < \infty$$

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \to \mu$$

Convergindo quase certo $n \to \infty$

$$P\left(\lim_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n} Y_i = \mu\right) = 1$$

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

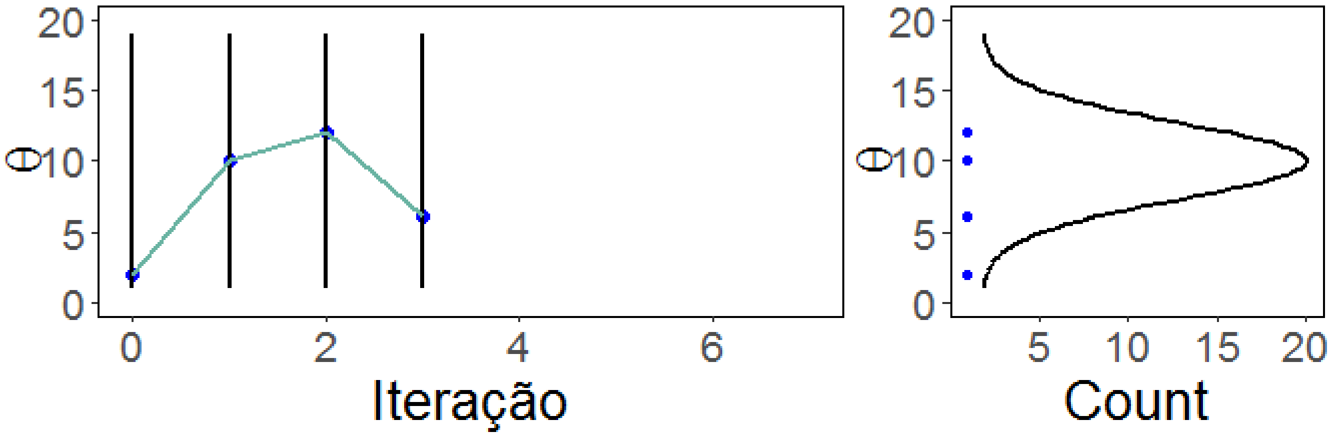

Geração de variáveis aleatórias independentes com mesma distribuição

➢ Lei Forte dos Grandes Números

Seja $Y_1, Y_2, \ldots, Y_n$ variáveis $i.i.d.$

$$\mu = E[Y] < \infty$$

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \to \mu$$ Convergindo quase certo $n \to \infty$

$$P\left(\lim_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n} Y_i = \mu\right) = 1$$

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

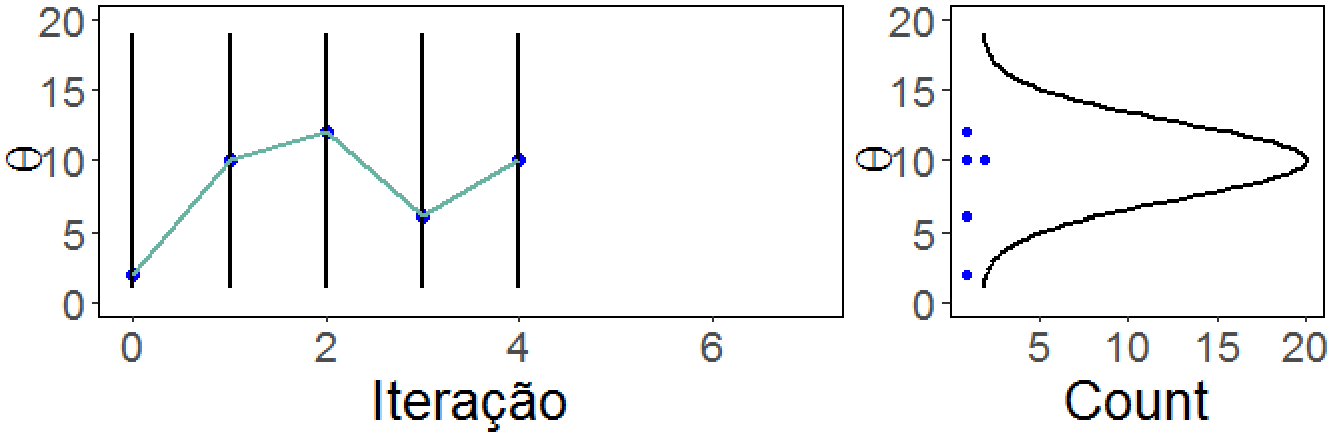

- Lei Forte dos Grandes Números

Seja $Y_1, Y_2, \ldots, Y_n$ variáveis *i.i.d.*

$$\mu = E[Y] < \infty$$

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \to \mu$$ Convergindo quase certo $n \to \infty$

$$P\left(\lim_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n} Y_i = \mu\right) = 1$$

Geração de variáveis aleatórias independentes com mesma distribuição

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

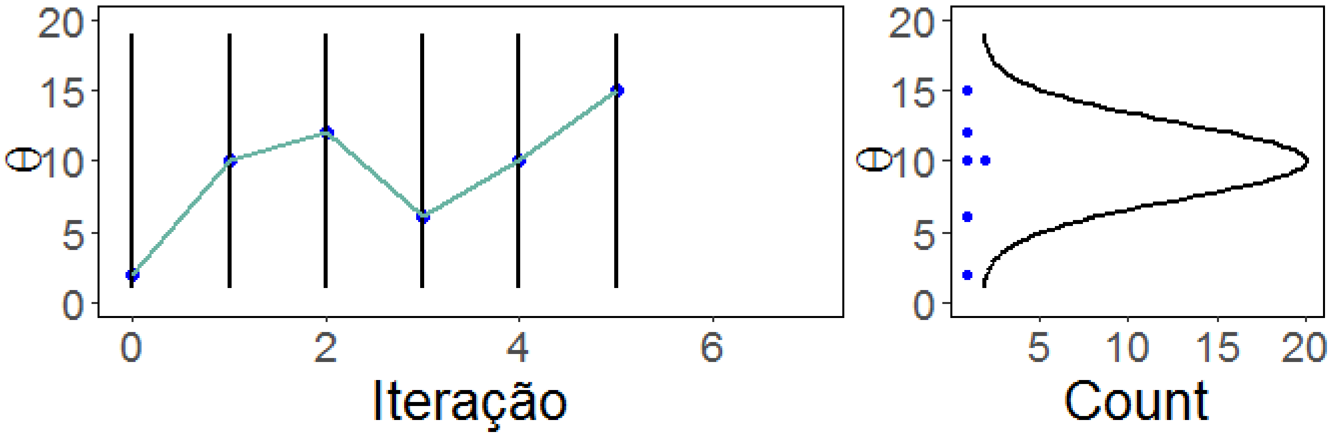

- Lei Forte dos Grandes Números

Seja $Y_1, Y_2, \ldots, Y_n$ variáveis $i.i.d.$

$$\mu = E[Y] < \infty$$

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \to \mu$$ Convergindo quase certo $n \to \infty$

$$P\left(\lim_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n} Y_i = \mu\right) = 1$$

Geração de variáveis aleatórias independentes com mesma distribuição

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

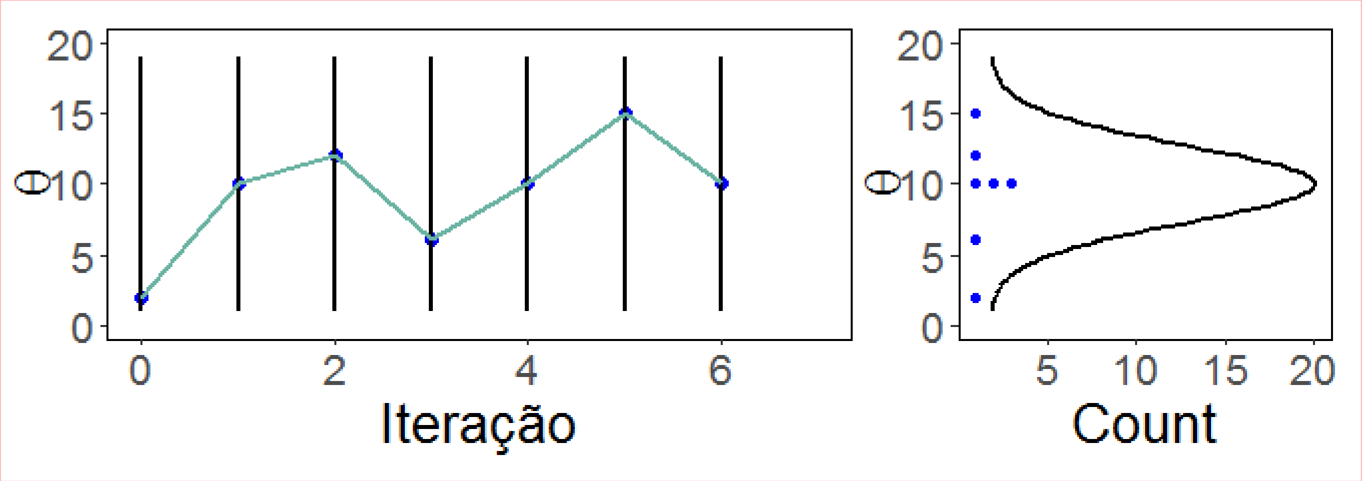

Geração de variáveis aleatórias independentes com mesma distribuição

➢ Lei Forte dos Grandes Números

Seja $Y_1, Y_2, \ldots, Y_n$ variáveis *i.i.d.*

$$\mu = E[Y] < \infty$$

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \to \mu$$

Convergindo quase certo

$$n \to \infty$$

$$P\left(\lim_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n} Y_i = \mu\right) = 1$$

Monte Carlo é um método de integração numérico conhecido:

- **Integração de Monte Carlo;**

ou

- **Método de Monte Carlo.**

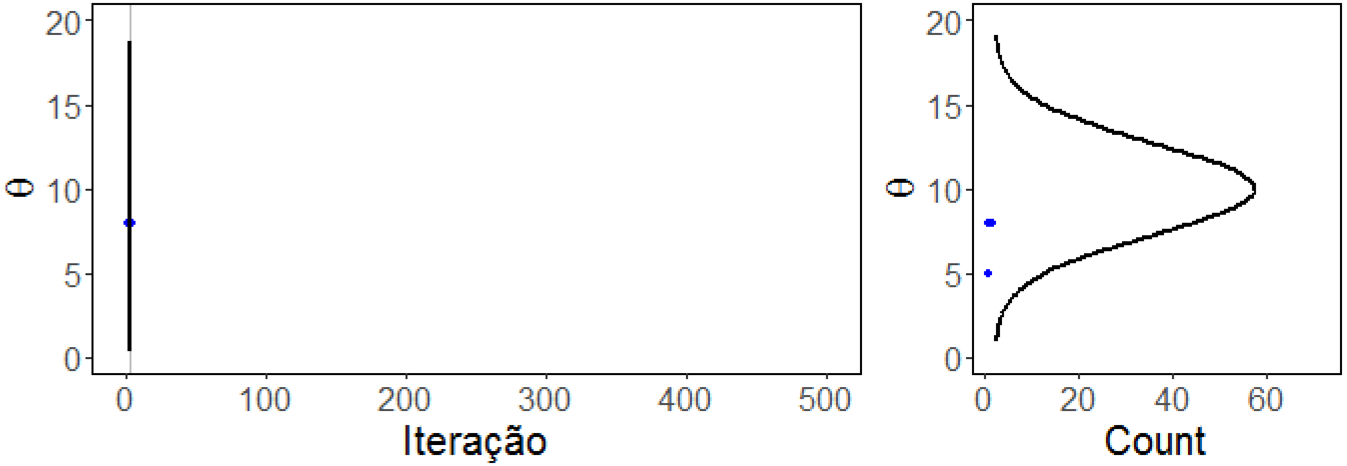

Geração de variáveis aleatórias independentes com mesma distribuição

- Lei Forte dos Grandes Números

Seja $Y_1, Y_2, \ldots, Y_n$ variáveis *i.i.d.*

$$\mu = E[Y] < \infty$$

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \to \mu$$ Convergindo quase certo $n \to \infty$

$$P\left(\lim_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n} Y_i = \mu\right) = 1$$

Monte Carlo Via Cadeia de Markov:

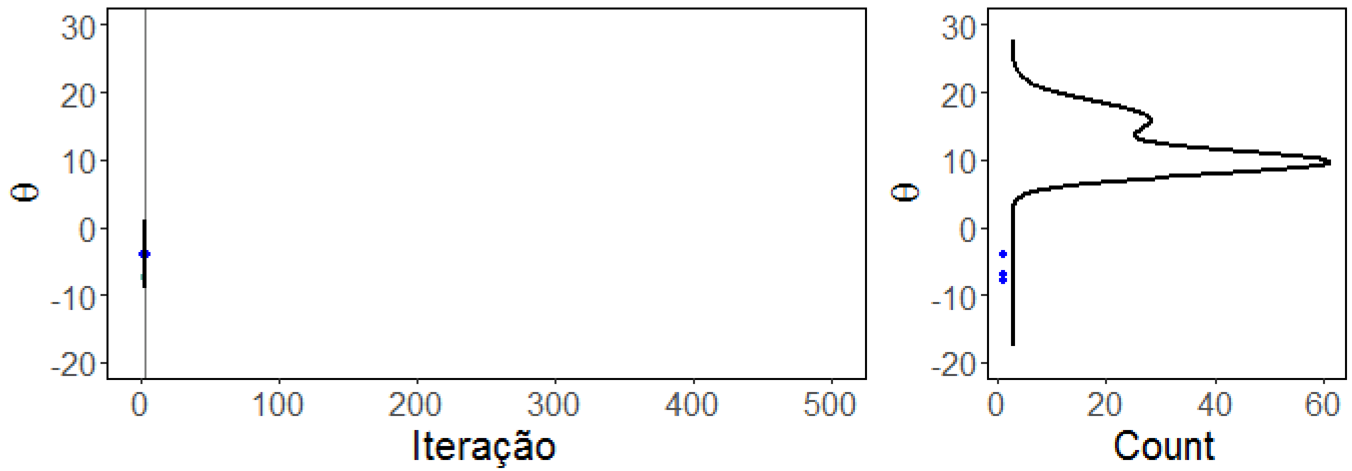

A posteriori: Bimodal

Distribuição Normal mista

$$f(x) = 0{,}4 * N(17; 3) + 0{,}6 * N(3; 2)$$

$$\theta_t \sim N(\theta_{t-1}; \sigma)$$

Geração de variáveis aleatórias ~~independentes~~ dependentes com mesma distribuição

Monte Carlo Via Cadeia de Markov:

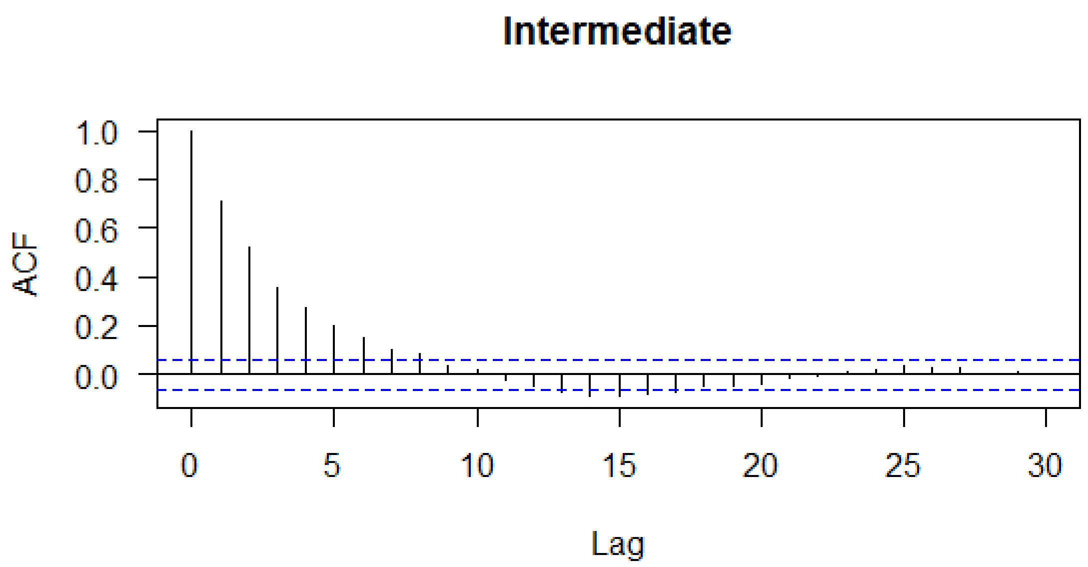

A posteriori: Bimodal

Distribuição Normal mista

$$f(x) = 0{,}4 * N(17; 3) + 0{,}6 * N(3; 2)$$

$$\theta_t \sim N(\theta_{t-1}; \sigma)$$

Geração de variáveis aleatórias ~~independentes~~ dependentes com mesma distribuição

Monte Carlo Via Cadeia de Markov:

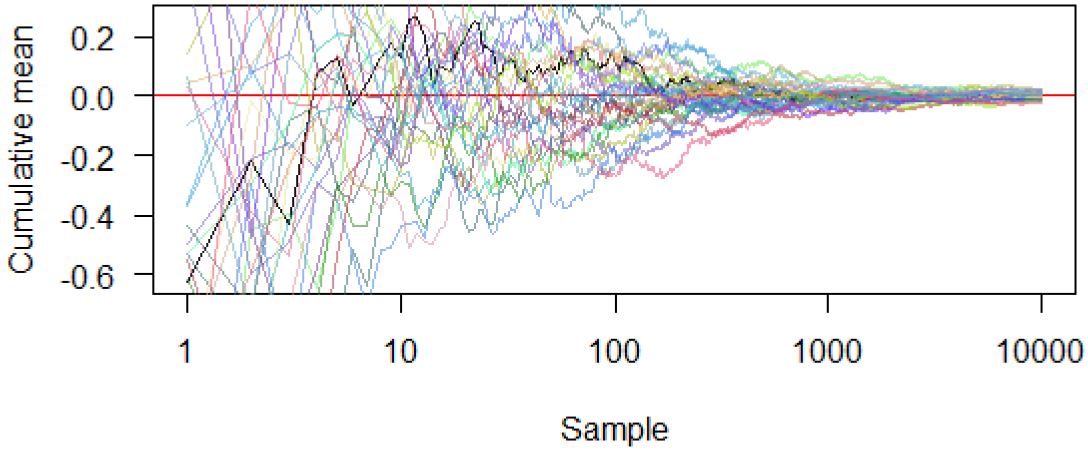

A posteriori: Bimodal
Distribuição Normal mista

$$f(x) = 0{,}4 * N(17;3) + 0{,}6 * N(3;2)$$

Geração de variáveis aleatórias ~~independentes~~ dependentes com mesma distribuição

Espaço paramétrico da distribuição *a posteriori*

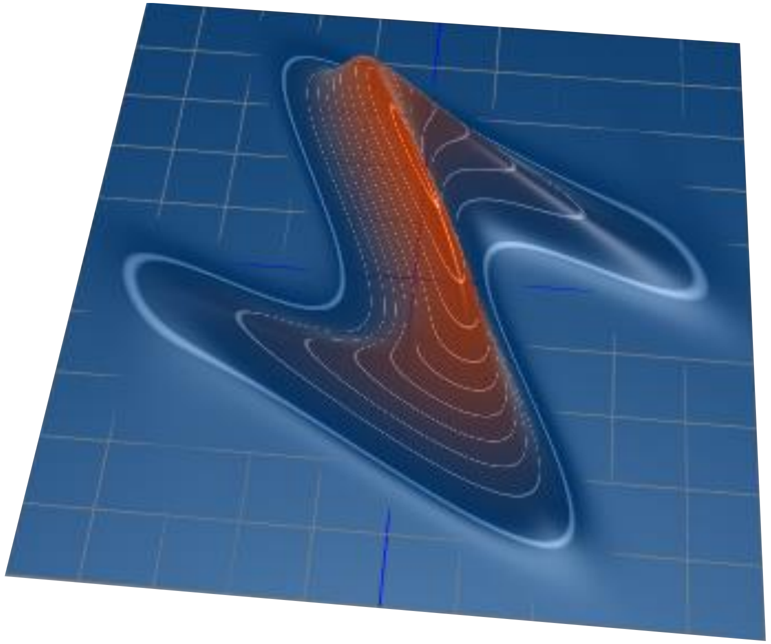

Espaço paramétrico da distribuição *a posteriori* ⇒ Desconhecido

Espaço paramétrico da distribuição *a posteriori*

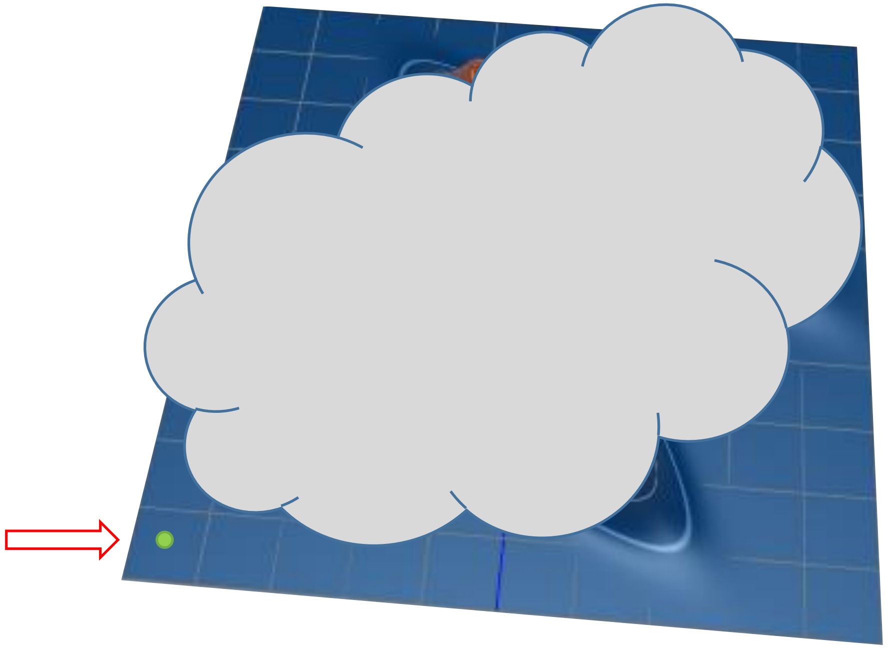

- *Random walk MCMC*

Espaço paramétrico da distribuição *a posteriori*

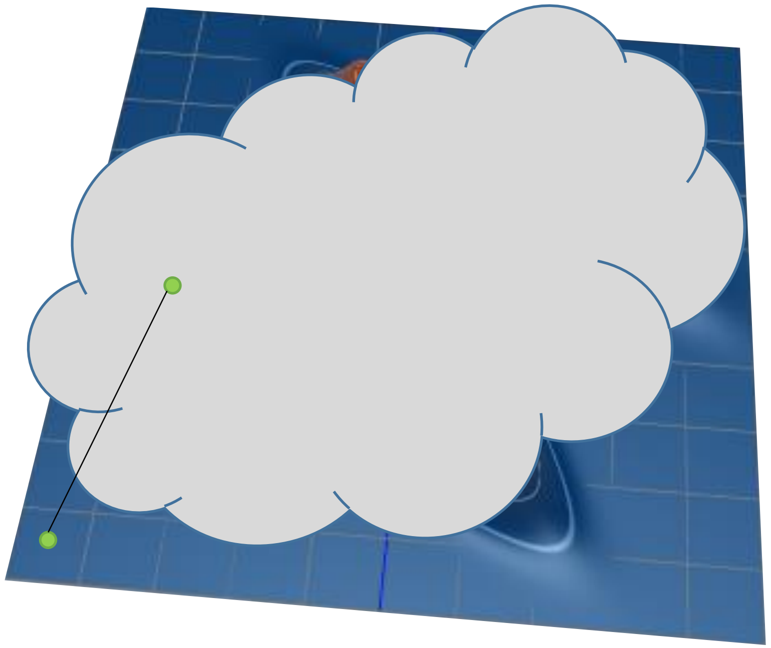

- *Random walk MCMC*

Espaço paramétrico da
distribuição *a posteriori*

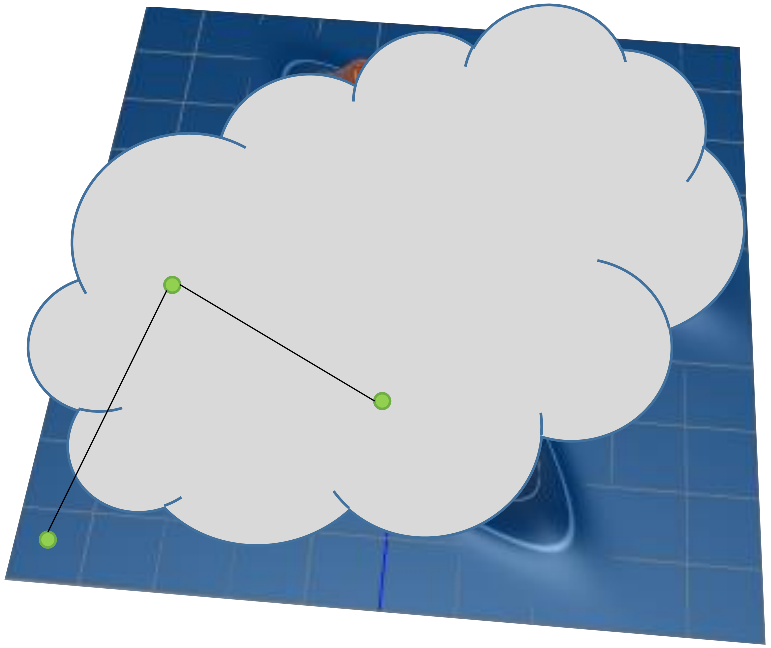

- *Random walk MCMC*

Espaço paramétrico da distribuição *a posteriori*

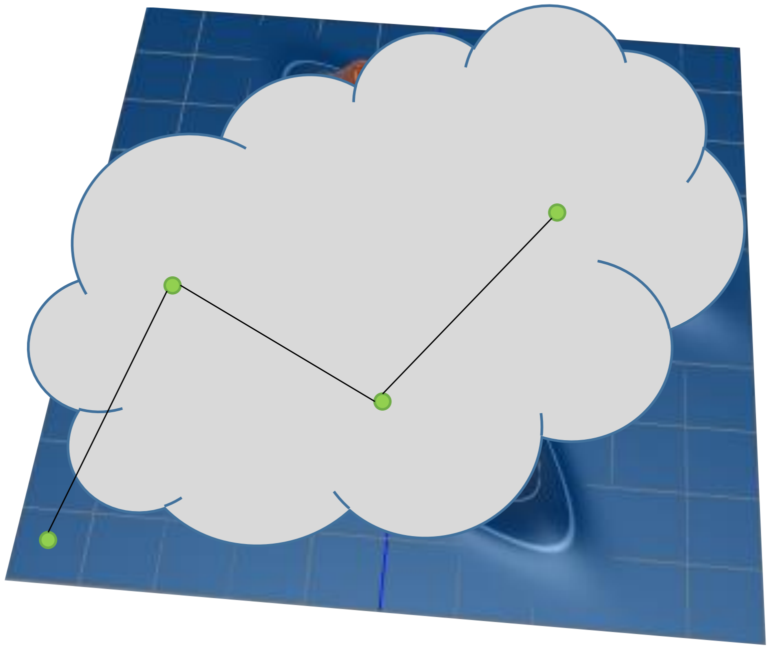

- *Random walk MCMC*

Custo computacional muito grande para amostrar todo o espaço paramétrico.

Espaço paramétrico da distribuição *a posteriori*

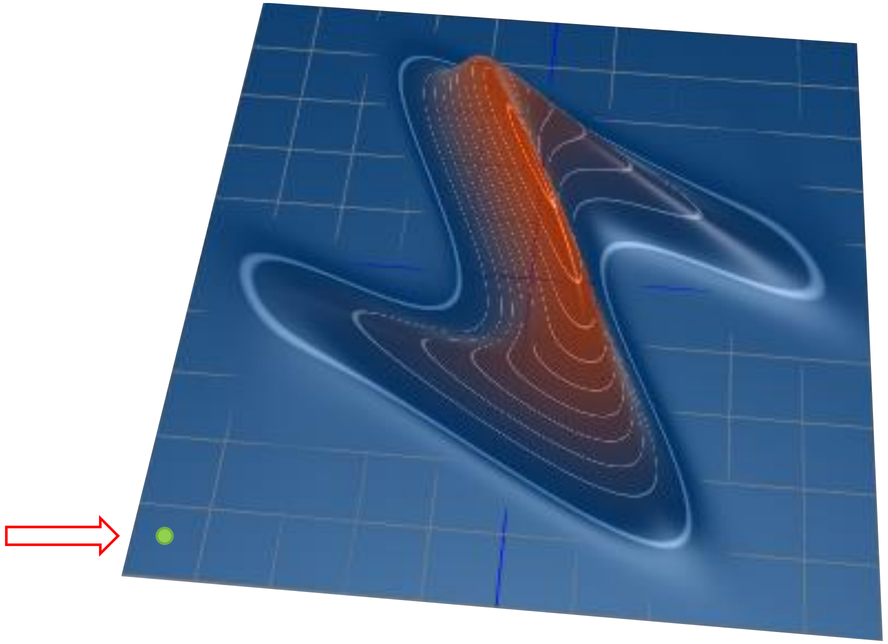

- *Random walk MCMC*

- <u>Método a amostragem:</u>
  - Gibbs
  - Metropolis-Hasting

Etapa de aceitação ou rejeição de cada iteração do passeio aleatório.

Espaço paramétrico da distribuição *a posteriori*

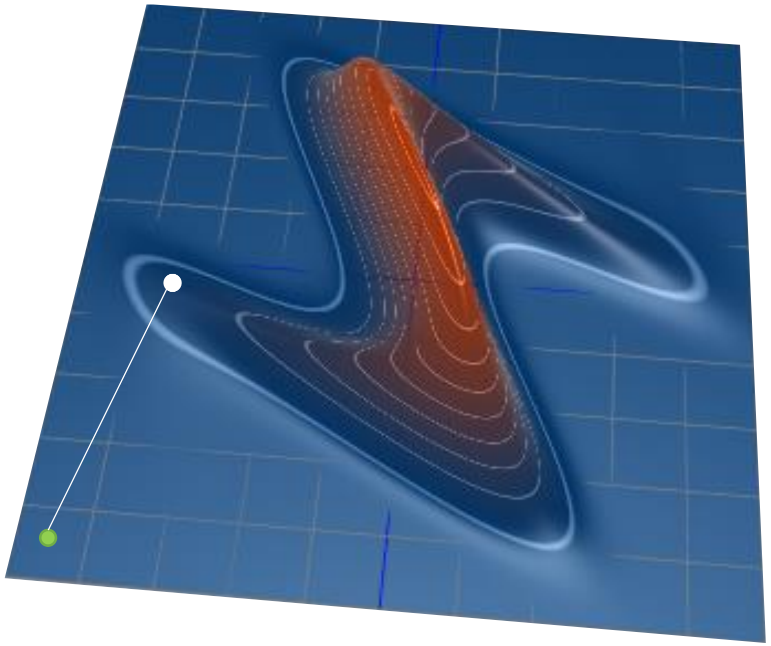

- *Random walk MCMC*
- Amostrador em avaliação;

- Método a amostragem:
  - Gibbs
  - Metropolis-Hasting

Etapa de aceitação ou rejeição de cada iteração do passeio aleatório.

Espaço paramétrico da
distribuição *a posteriori*

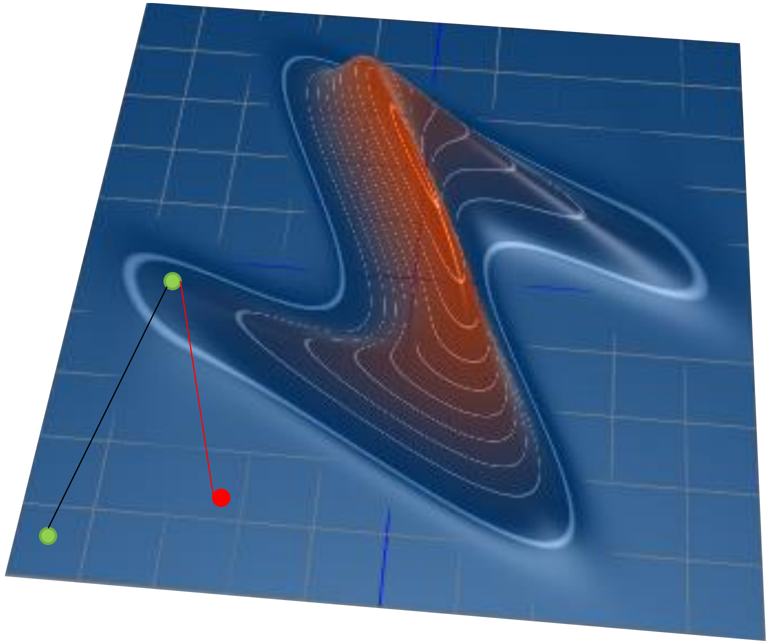

- *Random walk MCMC*
- Amostrador em avaliação;
- Amostrador rejeitado;

- Método a amostragem:
  - Gibbs
  - Metropolis-Hasting

Etapa de aceitação ou rejeição de cada iteração do passeio aleatório.

Espaço paramétrico da distribuição *a posteriori*

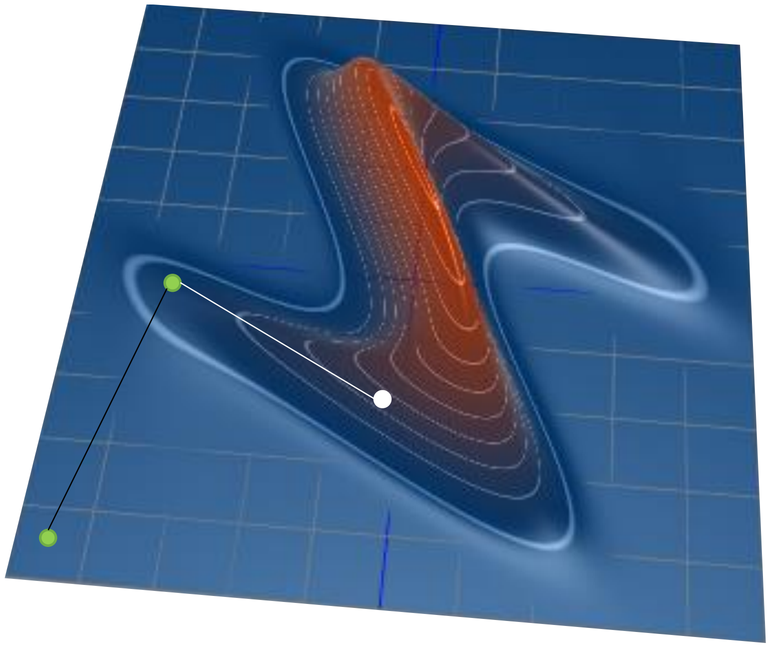

- *Random walk MCMC*
- Amostrador em avaliação;
- Amostrador rejeitado;

- <u>Método a amostragem:</u>
  - Gibbs
  - Metropolis-Hasting

Etapa de aceitação ou rejeição de cada iteração do passeio aleatório.

Espaço paramétrico da
distribuição *a posteriori*

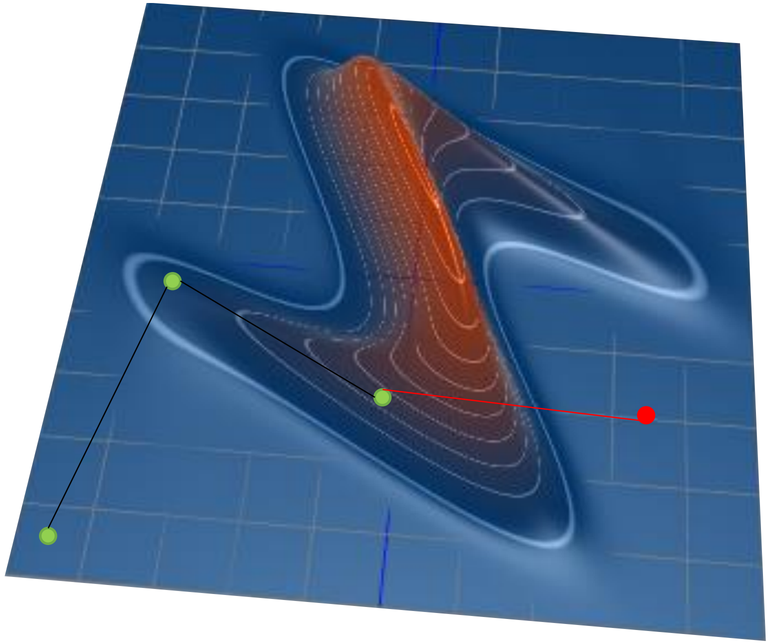

- *Random walk MCMC*
- Amostrador em avaliação;
- Amostrador rejeitado;

- Método a amostragem:
  - Gibbs
  - Metropolis-Hasting

Etapa de aceitação ou rejeição de cada iteração do passeio aleatório.

Espaço paramétrico da distribuição *a posteriori*

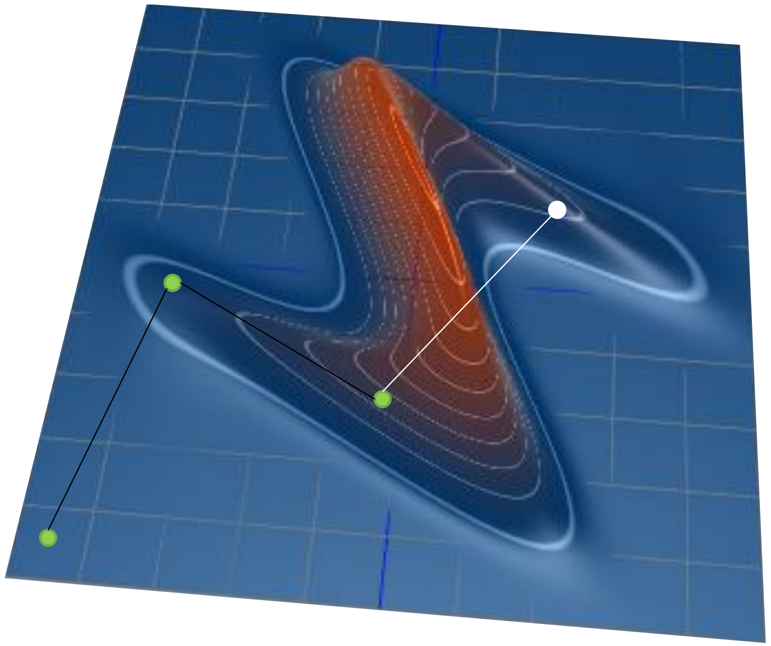

- *Random walk MCMC*
- Amostrador em avaliação;
- Amostrador rejeitado;

- <u>Método a amostragem:</u>
  - Gibbs
  - Metropolis-Hasting

Etapa de aceitação ou rejeição de cada iteração do passeio aleatório.

Espaço paramétrico da
distribuição *a posteriori*

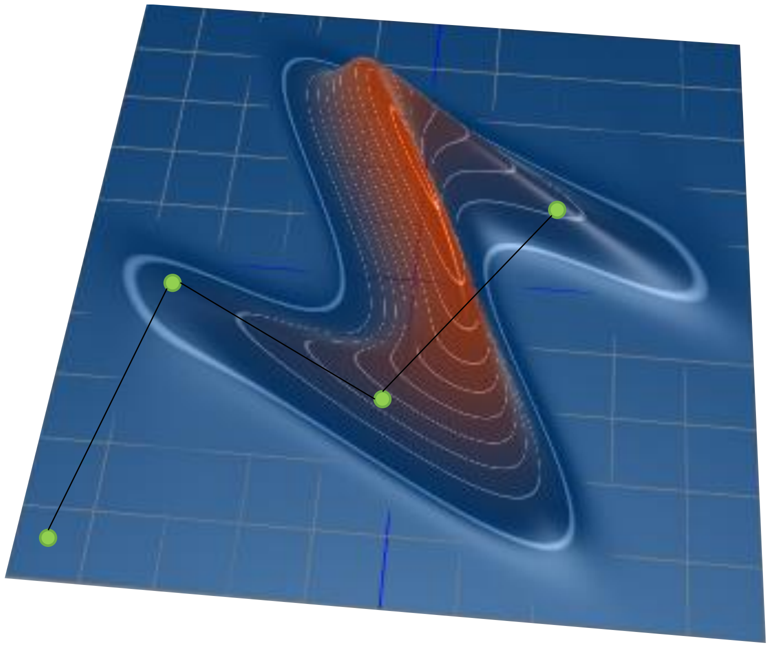

Random walk MCMC

Amostrador em avaliação;

Amostrador rejeitado;

- <u>Método a amostragem:</u>
  - Gibbs
  - Metropolis-Hasting

atenção

- Amostragem *a posteriori* é marginal por parâmetro;
- Lenta convergência;

(Principalmente espaços
paramétricos de alta
dimensão).

Espaço paramétrico da distribuição *a posteriori*

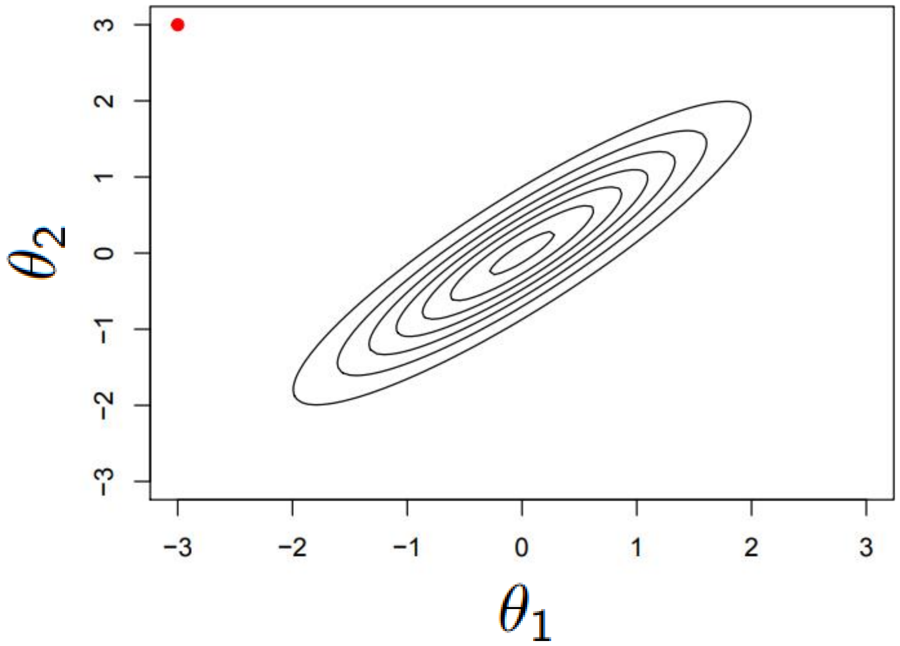

- <u>Método a amostragem:</u>
  - Gibbs — atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

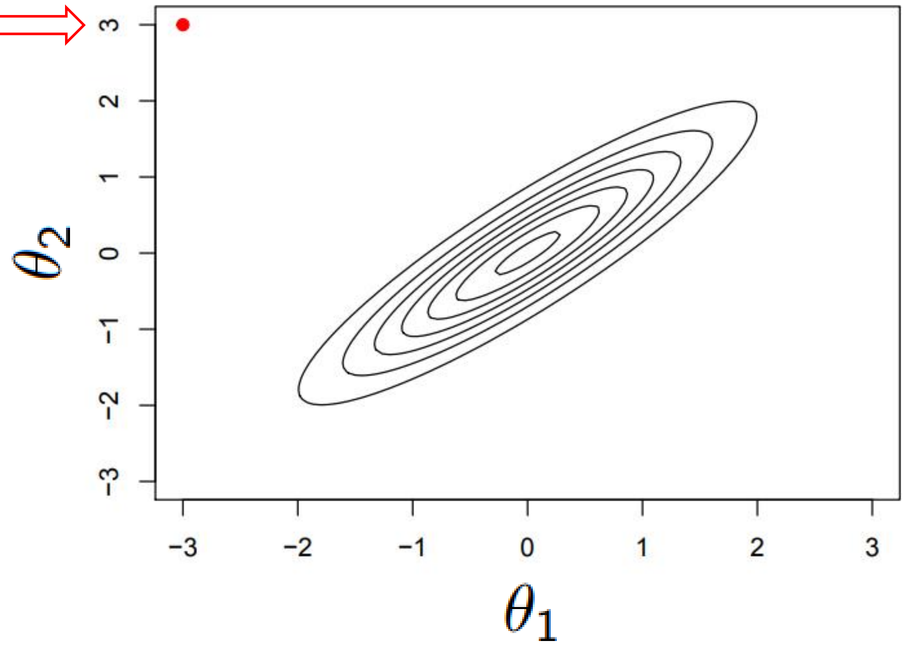

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- <u>Método a amostragem:</u>
  - Gibbs $\xrightarrow{\text{atenção}}$
  - Metropolis-Hasting
- Amostragem *a posteriori* é marginal por parâmetro;

$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

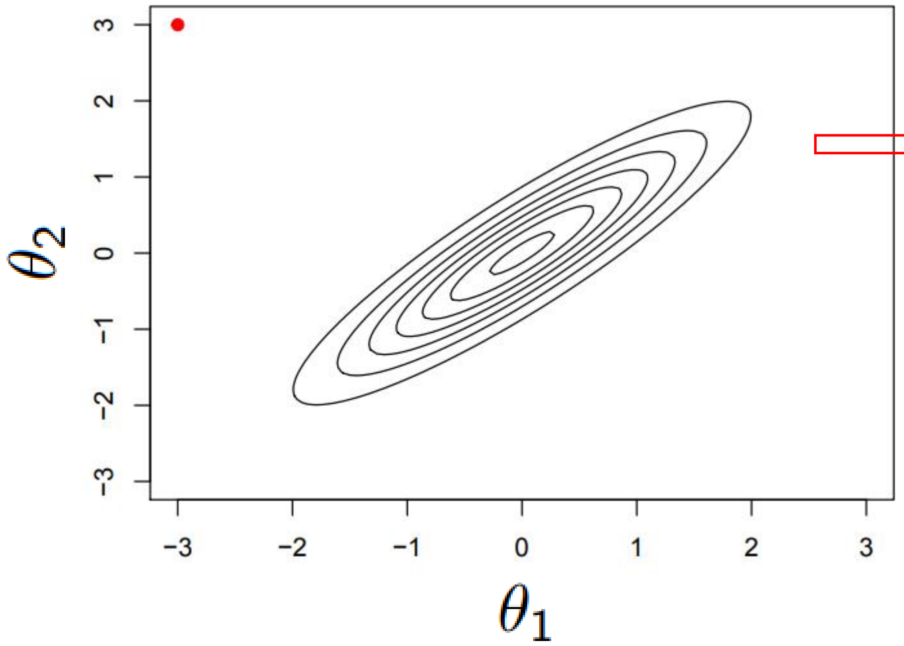

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- Método a amostragem:
  - Gibbs — atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

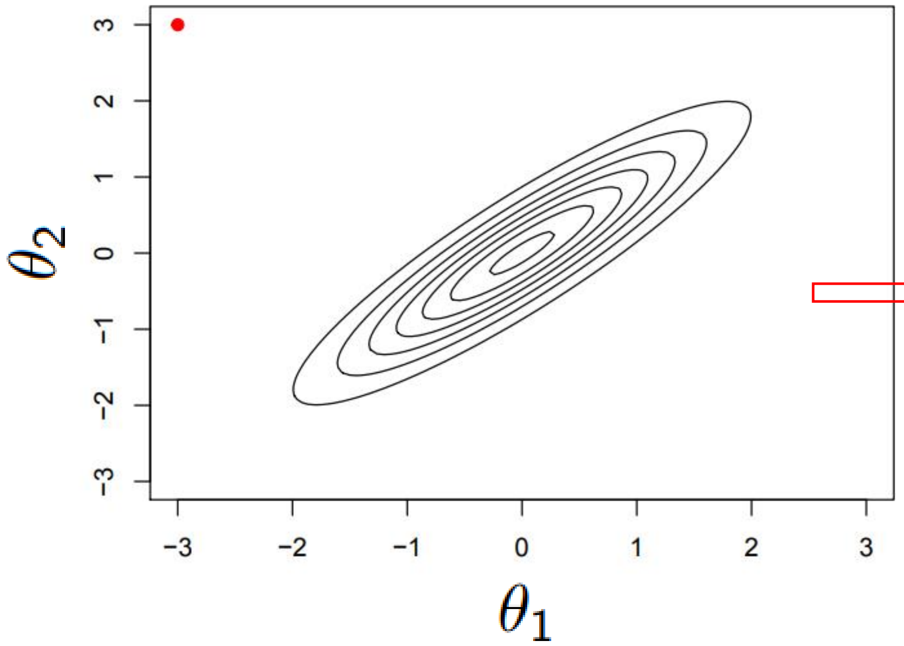

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- <u>Método a amostragem:</u>
  - Gibbs — atenção →
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

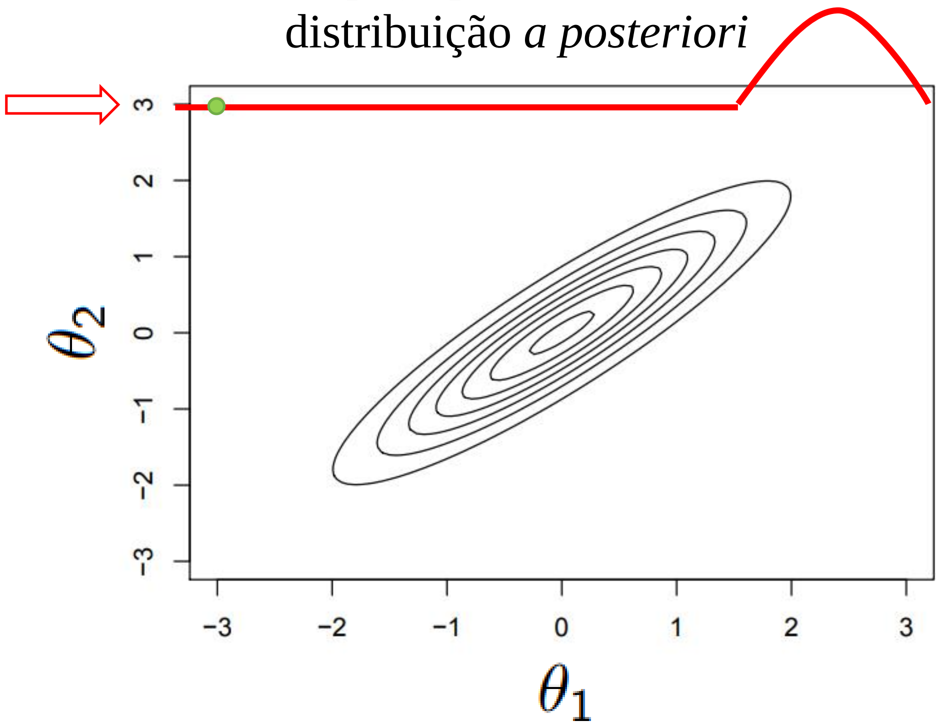

Fixar

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- Método a amostragem:
  - Gibbs — atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

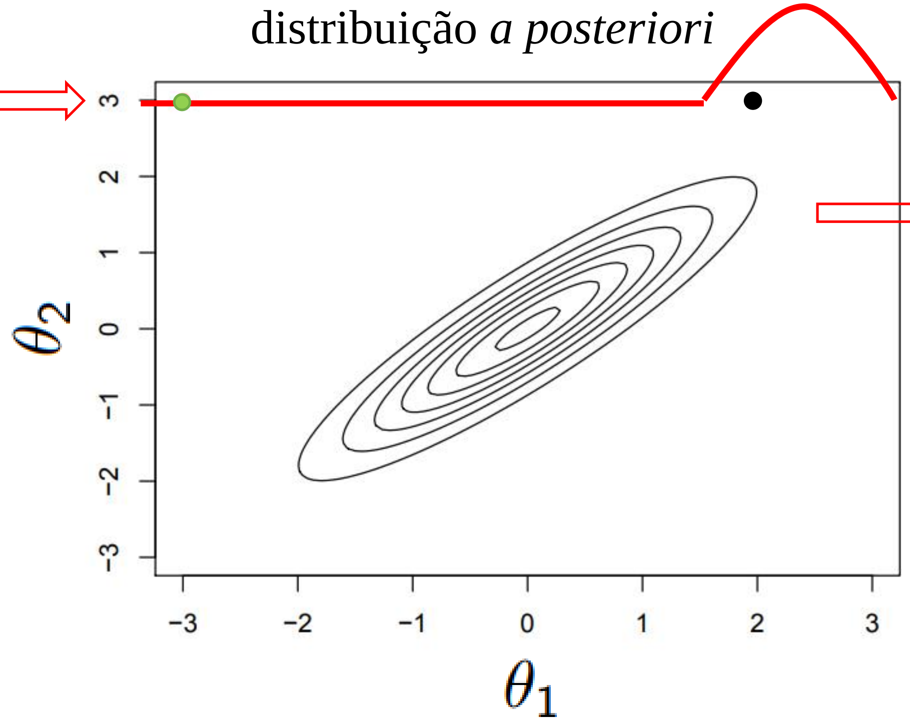

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- <u>Método a amostragem:</u>
  - Gibbs — atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

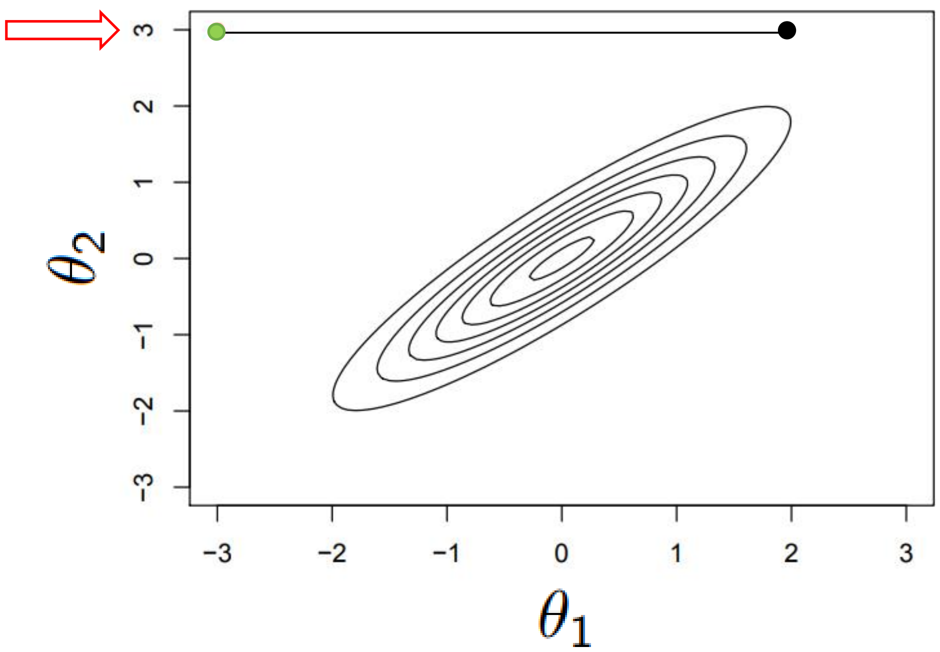

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- Método a amostragem:
  - Gibbs → atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

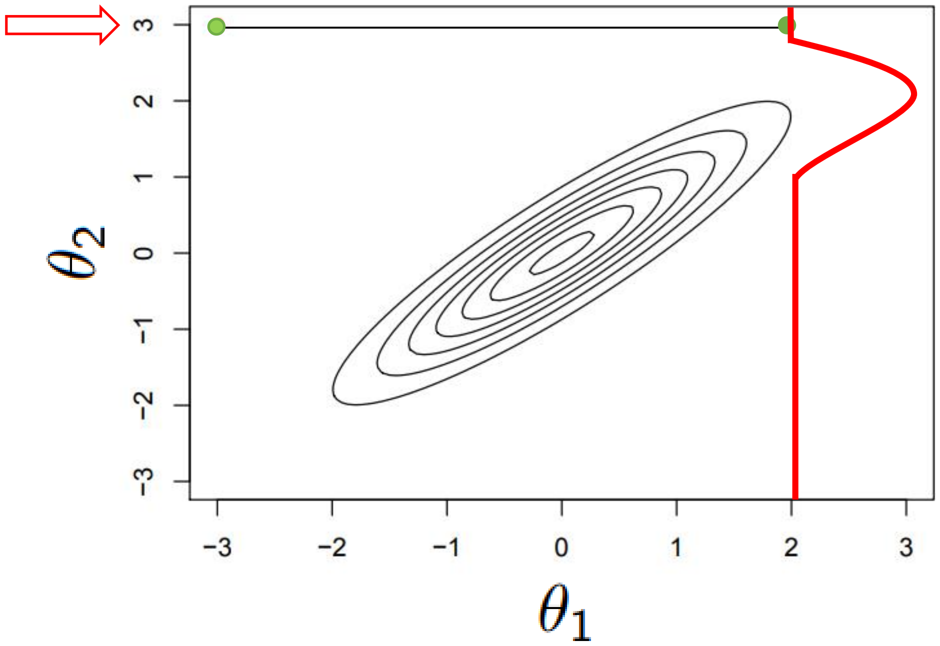

Fixar

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- <u>Método a amostragem:</u>
  - Gibbs — atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

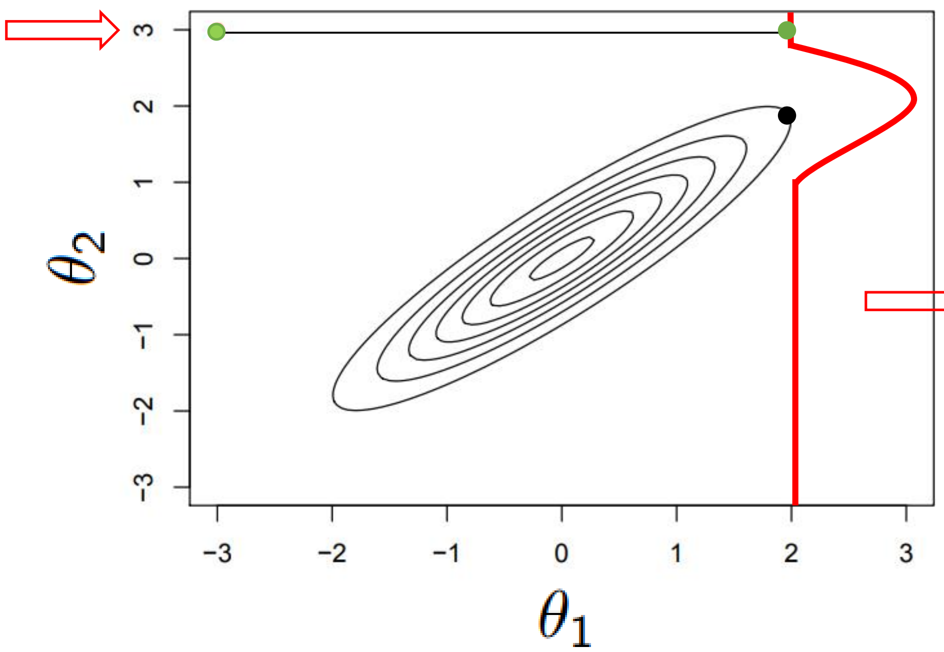

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- <u>Método a amostragem:</u>
  - Gibbs — atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

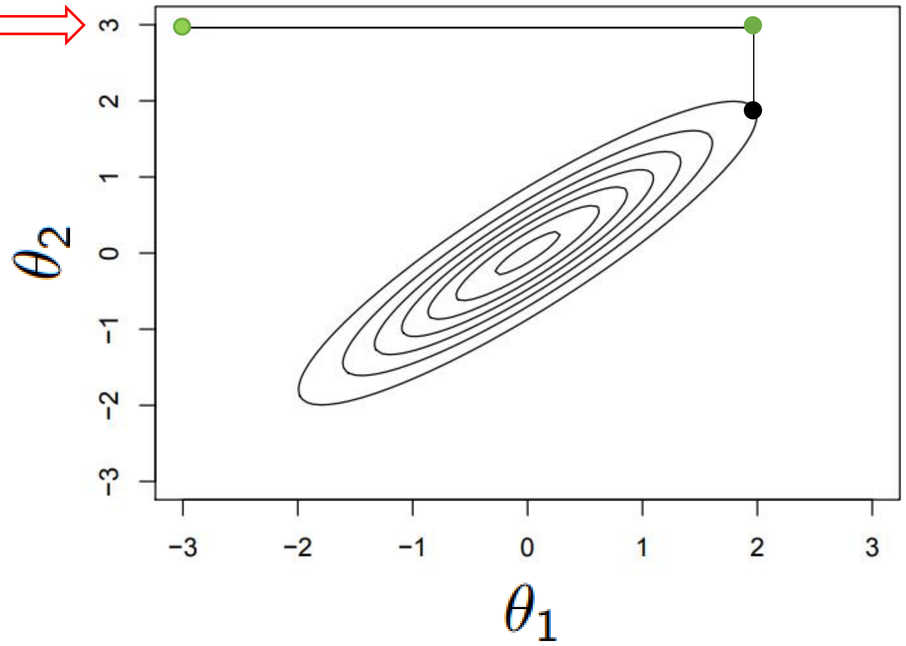

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- <u>Método a amostragem:</u>
  - Gibbs — atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

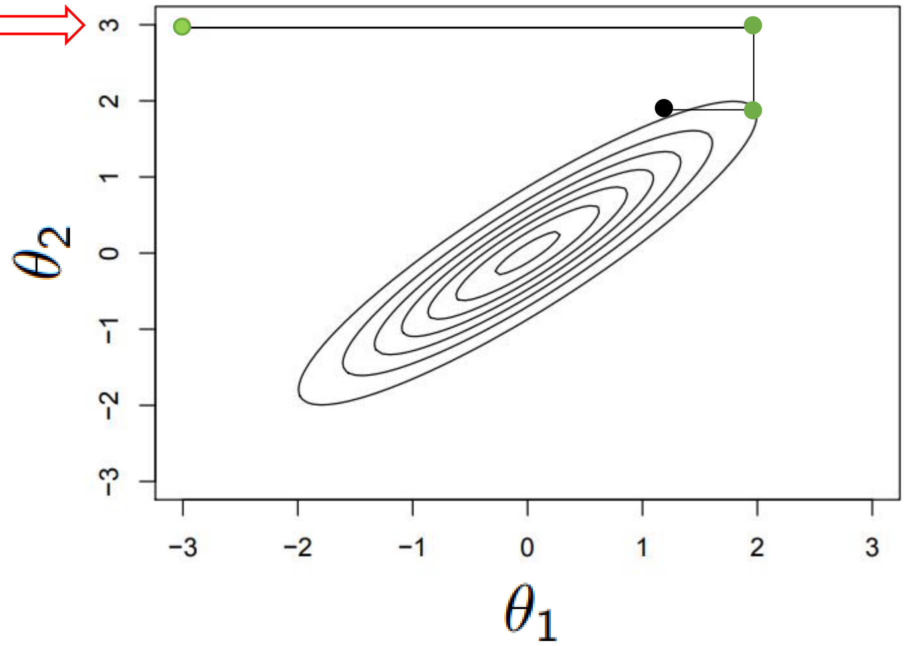

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- <u>Método a amostragem:</u>
  - Gibbs — atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$p(\theta|y) \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Distribuição Alvo

Espaço paramétrico da distribuição *a posteriori*

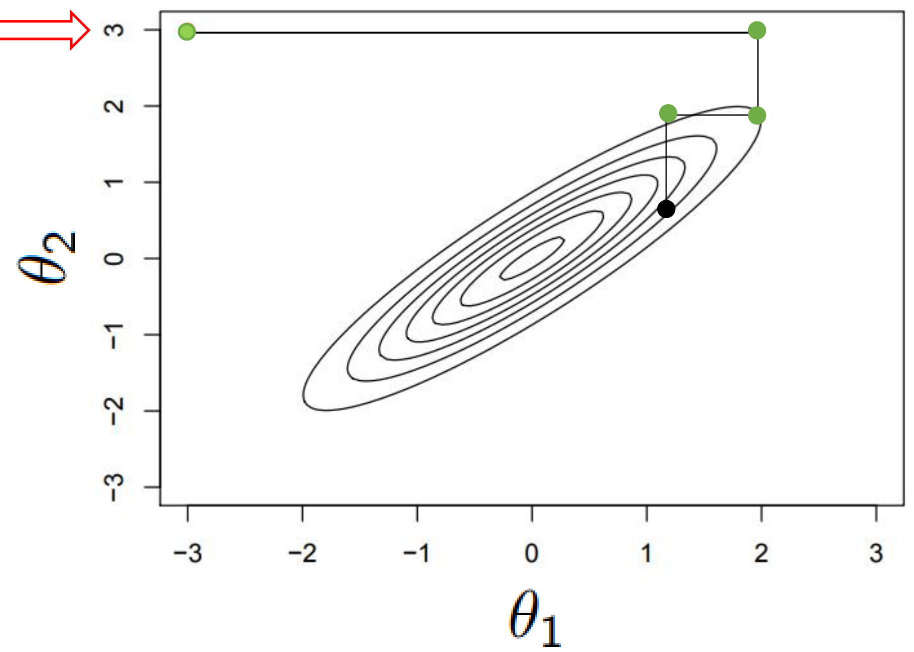

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- <u>Método a amostragem:</u>
  - Gibbs $\Longrightarrow$ atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$\underbrace{p(\theta|y)}_{\text{Distribuição Alvo}} \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Espaço paramétrico da distribuição *a posteriori*

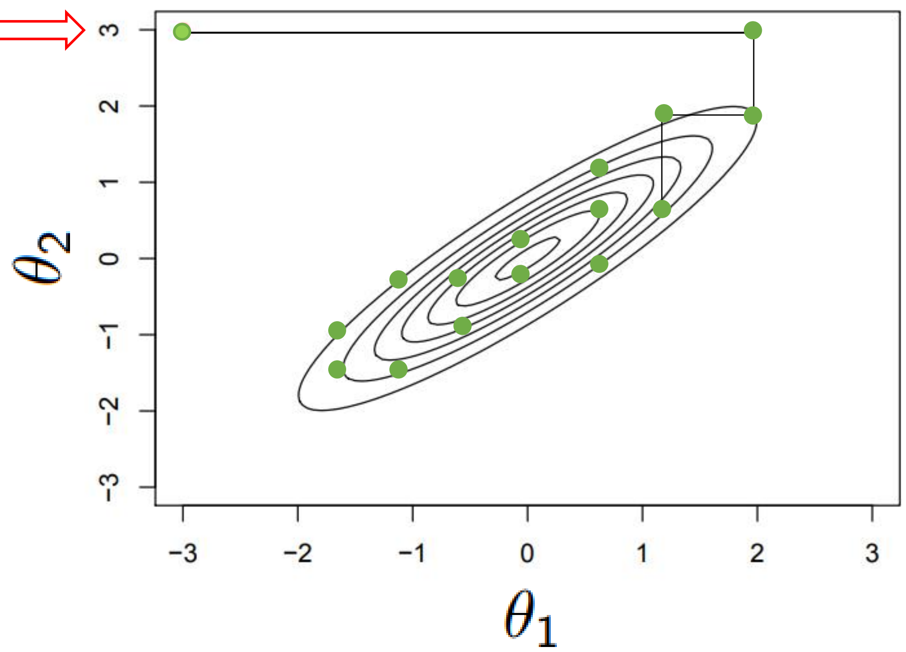

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- Método a amostragem:
  - Gibbs $\Longrightarrow$ atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;

$$\underset{\text{Distribuição Alvo}}{p(\theta|y)} \xrightarrow{\text{com}} \theta = (\theta_1, \theta_2) \xrightarrow{\text{amostrar}} \begin{cases} p(\theta_1|\theta_2, y) \\ p(\theta_2|\theta_1, y) \end{cases}$$

Espaço paramétrico da distribuição *a posteriori*

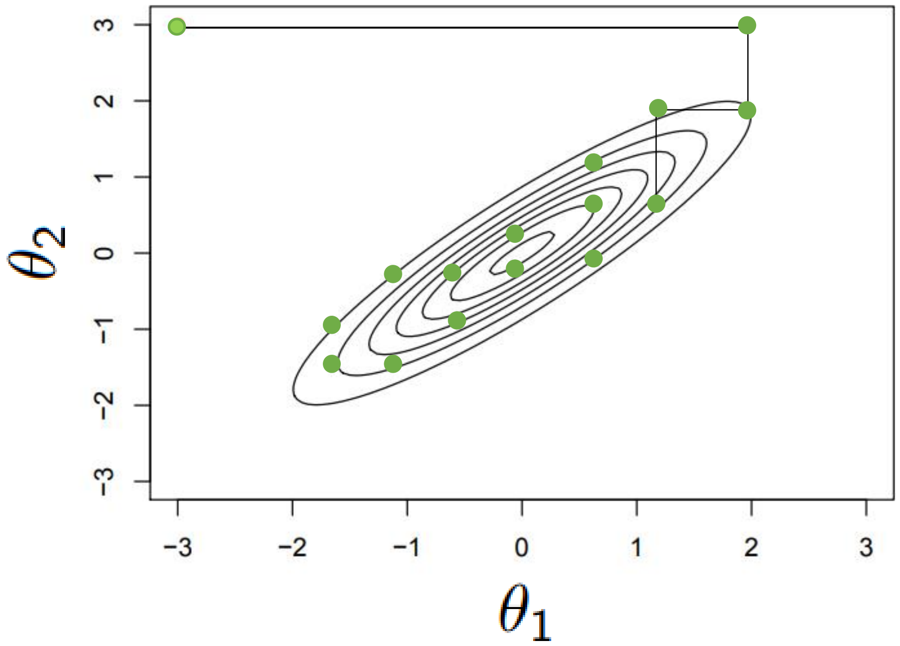

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- <u>Método a amostragem:</u>
  - Gibbs — atenção
  - Metropolis-Hasting

- Amostragem *a posteriori* é marginal por parâmetro;
- Lenta convergência;

(Principalmente espaços paramétricos de alta dimensão).

Espaço paramétrico da distribuição *a posteriori*

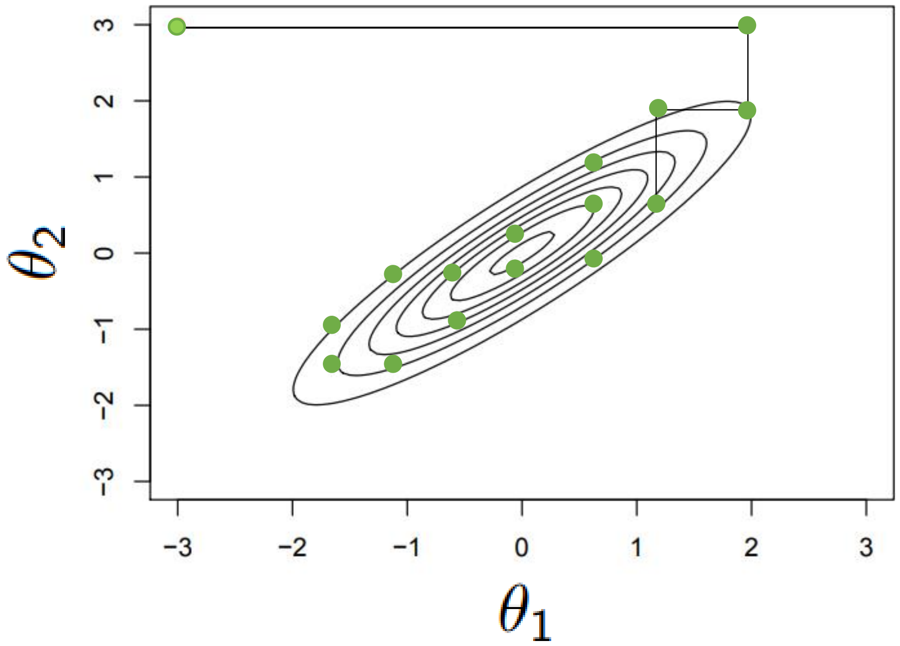

$$\left(\theta_1^{(0)}, \theta_2^{(0)}\right)$$

$$\theta_1^{(t)} \sim p\left(\theta_1 | \theta_2^{(t-1)}, y\right)$$

$$\theta_2^{(t)} \sim p\left(\theta_2 | \theta_1^{(t)}, y\right)$$

- <u>Método a amostragem:</u>
  - Gibbs
  - Metropolis-Hasting

atenção

- Amostragem *a posteriori* conjunta;
- Lenta convergência;

Proporção de teste (**aceitação**/**rejeição**) por iteração ainda é muito alta.

Estatísticas & Aquicultura.

Com: Carlos Antônio Zarzar

carloszarzar_@hotmail.com

Obrigado!
Bons estudos!

“Hierarquia, as vezes é necessário, entretanto nem sempre é preciso.”